Projekt z przedmiotu Bazy danych

Implementacja systemu realizującego wybrane podstawowe operacje na bazie Northwind

Bartosz Kordek
Marcin Włodarczyk
Grzegorz Zacharski

Stos technologiczny

- front-end: rezygnacja z tworzenia graficznego interfejsu użytkownika
- back-end: Node.js oraz Express.js (REST API)
- baza danych: grafowa baza danych Neo4j
- konteneryzacja: Docker
- system kontroli wersji: Git
- ciągła integracja (CI): GitHub Actions
- narzędzia: Postman

Dlaczego te technologie?

- Część technologii jest nam znana (JavaScript, Docker, GitHub Actions)
- Chęć poznania baz NoSQL oraz grafowej bazy danych Neo4j
- Łatwość połączenia z bazą danych Neo4j przy użyciu frameworka Express.js oraz Node.js
- Duża dostępność materiałów edukacyjnych w sieci związanych z wybranymi technologiami ze względu na ich popularność

Node.js oraz Express.js

Node.js

- otwartoźródłowe, wieloplatformowe środowisko uruchomieniowe do tworzenia aplikacji serwerowych w języku JavaScript
- odpowiednie np. do przeglądarkowych aplikacji czasu rzeczywistego (gry przeglądarkowe) oraz aplikacji używających wielu operacji wejścia/wyjścia
- powszechnie używane w aplikacjach komercyjnych (IBM, LinkedIn, Microsoft, Netflix, Yahoo!, Paypal)

Express.js

- otwartoźródłowy framework do tworzenia aplikacji serwerowych z wykorzystaniem Node.js
- najpopularniejszy framework dla back-endu wykorzystujący język JavaScript
- wykorzystywany do tworzenia aplikacji webowych (np. REST API) oraz mobilnych

Grafowe bazy danych

Na przykładzie Neo4J

Motywacja

- chęć poszerzenia swojej wiedzy
- wsparcie Neo4j dla JavaScript
- dobra dokumentacja oraz wiele dostępnych materiałów od Neo4j

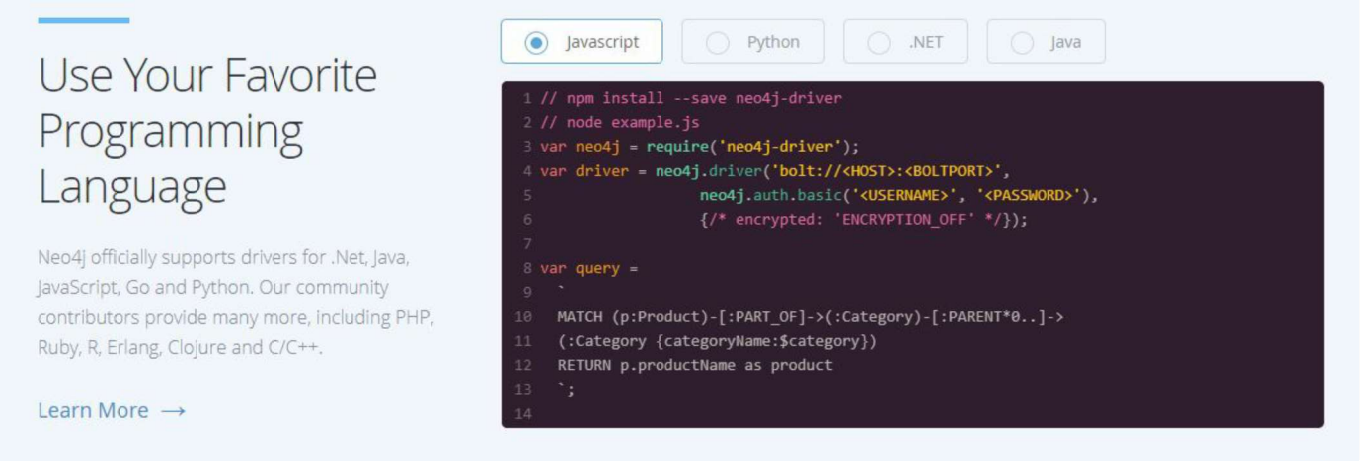

Czym jest grafowa baza danych?

- Jest to baza danych, która przechowuje dane i relacje między nimi w postaci grafu (najczęściej skierowanego).
- Zaprojektowana w taki sposób, by relacje między danymi były tak samo ważne jak same dane.
- Ma na celu przechowywanie danych bez ograniczania ich do wcześniej ustalonego modelu.

Z czego się składa?

Grafowa baza danych składa się z:

- **wierzchołka/węzłów -** mniej więcej odpowiednik **encji**
- **krawędzi/relacji -** opisuje **w jaki sposób** węzły są **połączone.** Zawsze posiada początek oraz koniec. Nazwa i kierunek pozwalają ustalić kontekst semantyczny jaki łączy dwa wierzchołki.

Każdy z wierzchołków oraz krawędzi może posiadać dowolną ilość:

- **etykiet -** jest to **nazwa** lub **identyfikator** wierzchołka lub krawędzi w grafie
- **właściwości -** są to elementy typu **klucz - wartość**. Zarówno wierzchołki oraz krawędzie mogą zawierać właściwości.

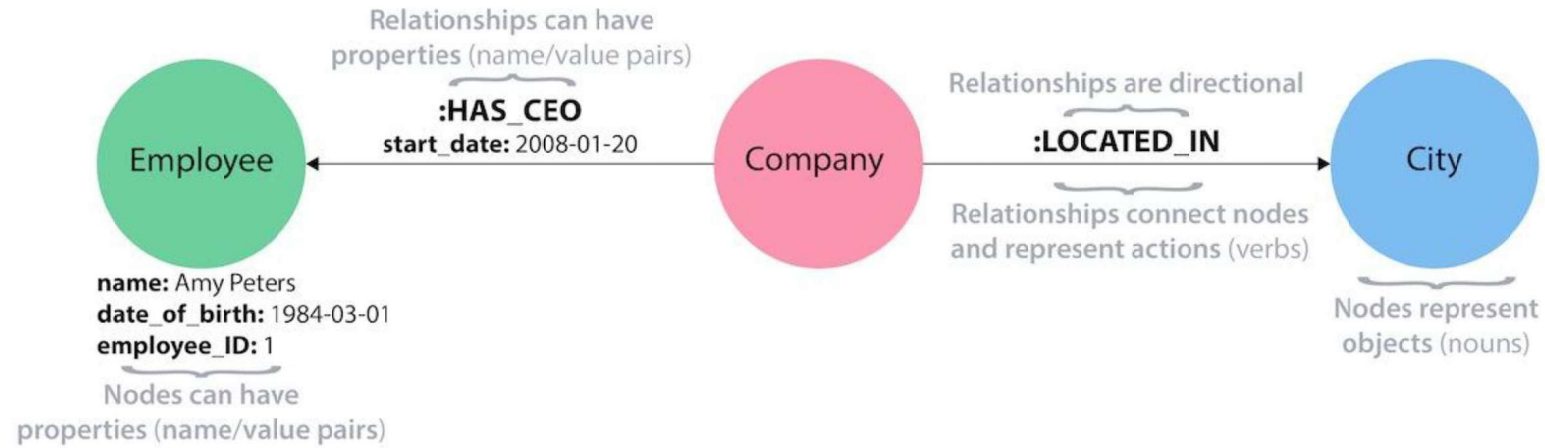
Relationships can have properties (name/value pairs)
:HAS_CEO
start_date: 2008-01-20
Employee
Company
Relationships are directional
:LOCATED_IN
Relationships connect nodes and represent actions (verbs)
City
name: Amy Peters
date_of_birth: 1984-03-01
employee_ID: 1
Nodes can have properties (name/value pairs)
Nodes represent objects (nouns)

Cypher

- deklaratywny język zapytań
- używany w bazie Neo4j
- składnia pozwala w wizualny i logiczny sposób dopasować wzorce pomiędzy wierzchołkami i relacjami jakie są w grafie
- pozwala dodawać oraz wyciągać dane z grafu

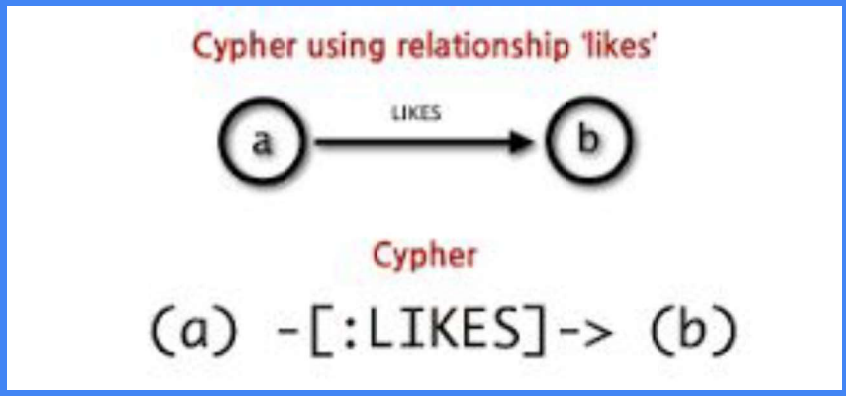

Cypher - podstawy

- ***(m:Movie)*** *- nawiasy okrągłe oznaczają wierzchołek*
- ***[d:Directed]*** *- nawiasy kwadratowe oznaczają relację*
- ***->*** *oznacza kierunek relacji*
- ***CREATE*** *- tworzenie danych*
- ***MATCH*** *- określa wzór który będzie wyszukiwany w bazie danych*
- ***RETURN*** *- definiuje co powinno być zwrócone z bazy danych, np. wierzchołki na podstawie ustalonego uprzednio wzorca*

Dopasuj osoby które grały razem w filmie z Tom Hanks. Zwróć film i aktora.

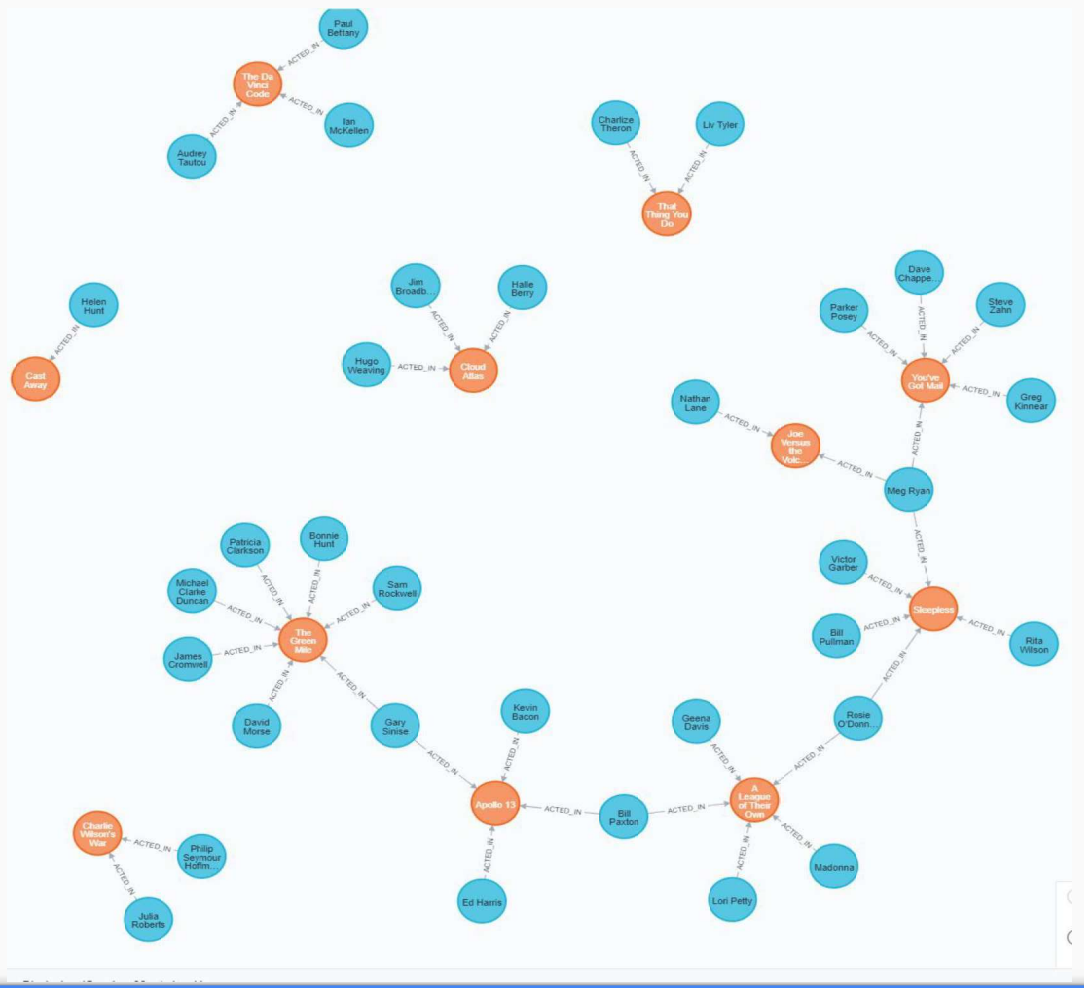

MATCH (tom:Person {name:'Tom Hanks'})-[:ACTED_IN]->(m:Movie)<-[:ACTED_IN]-(p:Person) RETURN p,m

Baza grafowa na przykładzie Northwind

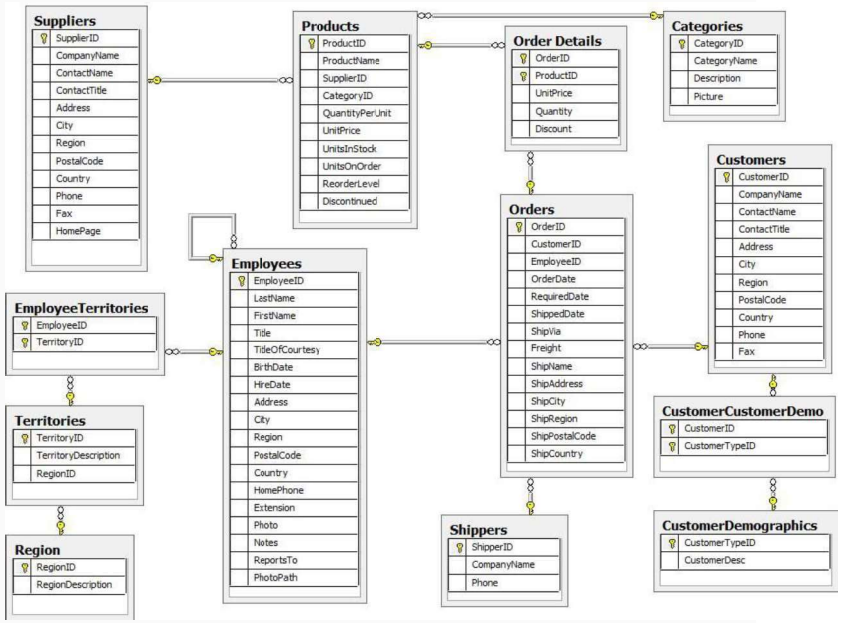

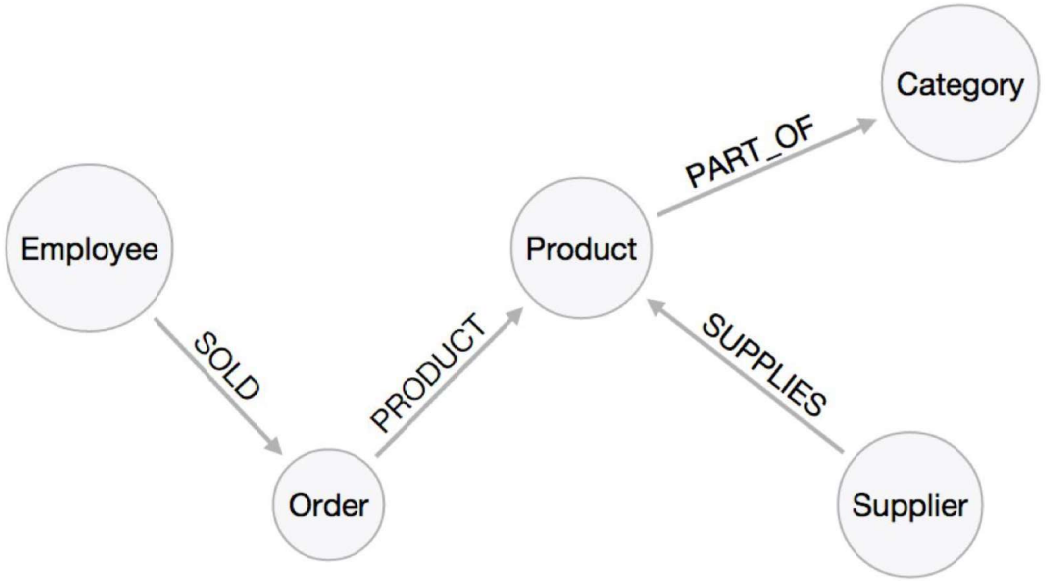

Zalety i wady neo4j

Zalety:

- bardzo szybki jeśli chodzi o wyszukiwanie zależności pomiędzy encjami
- elastyczne w rozbudowie
- wysoka wydajność odczytu i zapisu
- wsparcie wielu technologii/języków programowania, np. Java, .NET, JavaScript, Python, C/C++, Perl, PHP

Wady:

- brak jednego języka zapytań (ogólna wada podejścia grafowego)
- słaby mechanizm indeksowania
- mechanizm master-slave, master koordynuje wszystkie zapisy

Porównanie z relacyjnym modelem BD

RDBMS	Graph DB
Właściwości: *Sztywny model* - w przypadku zmiany konieczna przebudowa systemu, dodanie większej liczby encji i relacji wymaga ciągłego dbania o migracje i spójność	***Właściwości:*** *Brak sztywnego modelu* - w każdej chwili można stworzyć dowolny wierzchołek (wraz z właściwościami) lub krawędź; brak konieczności przebudowy całego modelu
Zastosowanie: systemy niewymagające wyszukiwania wzajemnego powiązania między elementami, np. systemy magazynowe	**Zastosowanie:** systemy wymagające wyszukiwania wzajemnego powiązania między elementami, np. social networks

Depth	RDBMS execution time(s)	Neo4j execution time(s)	Records returned
2	0.016	0.01	~2500
3	30.267	0.168	~110,000
4	1543.505	1.359	~600,000
5	Unfinished	2.132	~800,000

Porównanie wydajności rozwiązania relacyjnego oraz grafowego w znajdowaniu wzajemnych powiązań pomiędzy danymi.

Źródło:Graph Databases by Ian Robinson, Jim Webber and Emil aEifrem

Dziękujemy za uwagę!

Prezentację przygotowali:

Bartosz Kordek
Marcin Włodarczyk
Grzegorz Zacharski